Recommender – Dokumentacija

(Content-based recommender za Menultem u RestoraNow) **Datum:** 08.09.2025.

1) Sažetak (Šta radi sistem)

Sistem preporuke je **content-based**: za svaku stavku menija (Menultem) gradi se **vektor značajki** iz tekstualnih polja (*Name*, *CategoryName*, *Description*) pomoću **ML.NET** featurizacije teksta.

Za korisnika se pravi **profil** na osnovu njegovih **recenzija** i **narudžbi**, a zatim se dostupne stavke rangiraju po **kosinusnoj sličnosti** sa tim profilom.

Ako nema historije ili model nije izgrađen, radi cold-start fallback:

specijali dana \rightarrow najbolje ocijenjene \rightarrow ostale dostupne.

2) Arhitektura (komponente i lifecycle)

- Klasa: MenuRecommendationService : IMenuRecommendationService
 - Zavisnost: ApplicationDbContext (EF Core).
 - Statički cache:
 - MLContext _ml
 - Dictionary<int, float[]> _itemVectors (mapiranje MenultemId → vektor).
 - Thread-safe inicijalizacija modela uz lock (_sync).
 - Lijena inicijalizacija: model i vektori se grade prvi put kad se servis kreira/pozove.

Napomena o DI životnom ciklusu: zbog EF Core DbContext (obično **Scoped**), servis registirajte kao **Scoped** (ne kao Singleton). Statički cache i dalje dijeli vektore među instancama.

3) Kako radi (korak-po-korak)

- 1. Izgradnja vektora za sve stavke
 - Učita se lista Menultem (+ Category), za svaku se spoje tekstovi: Name, CategoryName, Description.
 - ML.NET pipeline (vidi §4) izgradi Features i normalizira ih.
 - Rezultat se spremi u _itemVectors[MenultemId] = float[].
- 2. Korisničke interakcije → težine

- Recenzije (MenultemReview): za svaki ocijenjeni item
 Težina = 2 x (Rating / 5) → raspon 0.2–1.0 x 2.
- Narudžbe (OrderItem): težina = Quantity (min 1).
- Ako nema interakcija → cold-start.

Profil korisnika

Izračuna se ponderisani prosjek vektora stavki sa dobijenim težinama.

4. Kandidati i rangiranje

- Kandidati = sve dostupne stavke (IsAvailable == true) koje korisnik nije već ocjenjivao/naručivao (isključujemo viđene).
- Za svakog kandidata računa se kosinusna sličnost sa profilom.
- Vraća se top N (parametar take, podrazumijevano 10).

5. Cold-start fallback

- Ako nema profila ili nema kandidata:
 - a) IsSpecialOfTheDay == true (ograniči na take)
 - b) Top-ocijenjene po prosjeku i broju recenzija (do popune)
 - c) Ostale dostupne (do popune).

4) ML.NET pipeline (vektorizacija)

- FeaturizeText("NameFeats", Name)
- FeaturizeText("CatFeats", Category)
- FeaturizeText("DescFeats", Description)
- Concatenate("Features", "NameFeats", "CatFeats", "DescFeats")
- NormalizeLpNorm("Features")

Pipeline se **fit-uje jednom**, transformira sve stavke i rezultat drži u memoriji (_itemVectors).

5) Pretpostavke o podacima (EF/DB)

- Menultem: Id, Name, Description, IsAvailable, IsSpecialOfTheDay, CategoryId, Category.Name
- MenultemReview: MenultemId, UserId, Rating
- Order: Id, UserId
- OrderItem: OrderId, MenuItemId, Quantity, Order.UserId

Ako je šema različita, prilagoditi LINQ upite u sekcijama za recenzije i narudžbe.

6) Funkcije i formule (suština)

- Ponderisani prosjek (profil):
 - Za svaku stavku i sa težinom w_i i vektorom v_i: profil = (Σ w i * v i) / (Σ w i)
- Kosinusna sličnost (rangiranje):
 - o $cos(a, b) = (a \cdot b) / (||a|| \times ||b|| + \varepsilon) (\varepsilon radi numeričke stabilnosti)$

7) Performanse i kompleksnost

- **Izgradnja modela:** O(N) po broju stavki (radi se jednom po procesu).
- Skoriranje: O(M × D)
 - M = broj kandidata, D = dimenzija vektora.
- Memorija: linearna u broju stavki (pohrana float[] vektora).

8) Edge slučajevi i fallback

- Prazna baza / nema vektora → cold-start.
- Korisnik bez historije → cold-start.
- Nema kandidata nakon filtriranja → cold-start.

9) Integracija (primjer korištenja)

Registracija servisa (Program.cs):

builder.Services.AddScoped<IMenuRecommendationService, MenuRecommendationService>();

Primjer endpointa (User-scoped preporuke):

```
[ApiController]
[Route("api/MenuItem")]
[Authorize]
0 references
public class MenuItemRecommendationsController: ControllerBase
    // GET: /api/MenuItem/recommendations?take=10
    [HttpGet("recommendations")]
    public async Task<ActionResult<IEnumerable<MenuItemResponse>>> GetRecommendations(
        [FromServices] IMenuRecommendationService recommender,
        [FromQuery] int take = 10,
        CancellationToken ct = default)
        var claimVal = User?.FindFirst(ClaimTypes.NameIdentifier)?.Value;
        if (!int.TryParse(claimVal, out var userId))
            return Unauthorized();
        var recItems = await recommender.RecommendAsync(userId, take, ct);
        return Ok(recItems);
```

Poziv sa klijenta: GET /api/menu/recommendations?take=10 (JWT obavezan).

10) Testiranje i validacija

- Jedinice:
 - o Cosine(a,b) provjeriti rubne slučajeve (prazni vektori, različite dužine).
 - WeightedAverage(weights) normalizacija i ponašanje za wsum=0.
- Integracija (mali uzorak):
 - 5–10 stavki sa poznatim opisima, par recenzija i narudžbi → provjeriti da preferirane stavke zaista izlaze u top-N.
- Load test:
 - Mjerenje vremena za M≈1000 kandidata (prosječna dimenzija od FeaturizeText), cilj < 50–100 ms na serveru prosječne snage.

11) Ograničenja i prijedlozi za unapređenje

- 1. Invalidacija modela/cachea
 - Trenutno se gradi jednom. Dodati osvježavanje:
 - Na CRUD promjene MenuItem/Category,
 - Periodično (npr. timer), ili
 - "Cache stamp" + signal (npr. via event ili Redis pub/sub).
- 2. Vremenski raspad (time-decay)

Novije recenzije/narudžbe neka vrijede više (npr. w = baseWeight × exp(-λ × ageDays)).

3. Diverzitet rezultata

Penalizirati previše slične stavke (MMR – Maximal Marginal Relevance).

4. Hybrid pristup

 Kombinovati sa kolaborativnim filtriranjem kada skup korisnika/ocjena naraste.

5. Jezička podešavanja

 Prilagoditi tokenizaciju/stop-riječi lokalnom jeziku ili preći na naprednije embedinge (npr. sentence transformers) ako zatreba.

6. Operativno

- Logirati rebuild modela, vrijeme skoriranja i veličinu kandidata.
- Postaviti metrike (npr. prosječan kosinus top-N, CTR).

12) Kratak pseudokod (za orijentir)

```
model build
private void BuildModelIfNeeded()
    if (_itemVectors != null) return;
    lock (_sync)
        if (_itemVectors != null) return;
        _ml = new MLContext(seed: 1);
        var rows = LoadItemRows();
        if (rows.Count == 0)
             _itemVectors = new Dictionary<int, float[]>();
        var data = _ml.Data.LoadFromEnumerable(rows);
        var pipeline =
             _ml.Transforms.Text.FeaturizeText("NameFeats", nameof(ItemRow.Name))
             .Append(_ml.Transforms.Text.FeaturizeText("CatFeats", nameof(ItemRow.Category)))
.Append(_ml.Transforms.Text.FeaturizeText("DescFeats", nameof(ItemRow.Description)))
             .Append(_ml.Transforms.Concatenate("Features", "NameFeats", "CatFeats", "DescFeats"))
             .Append(_ml.Transforms.NormalizeLpNorm("Features"));
        var model = pipeline.Fit(data);
        var transformed = model.Transform(data);
        var vectors = _ml.Data.CreateEnumerable<VectorRow>(transformed, reuseRowObject: false);
         _itemVectors = vectors.ToDictionary(v => v.MenuItemId, v => v.Features);
```

13) Cold-start detalji

- 1. IsSpecialOfTheDay == true (do take).
- 2. Preostalo popuniti top-ocijenjenim po prosjeku Rating i zatim po Count recenzija.
- 3. Ako još fali, uzeti **bilo koje dostupne** (IsAvailable == true) po alfabetu ili po nekom poslovnom kriteriju.